



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

AmbraIA: Memoria, apprendimento e pianificazione per NPC in ambienti 3D con LLM locale

RELATORE

Prof. Fabio Palomba

Dott. Antonio Della Porta

Dott.ssa Viviana Pentangelo

Università degli Studi di Salerno

CANDIDATO

Giovanni De Caro

Matricola: 0512119354

Anno Accademico 2026-2027

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Dedica o citazione

Abstract

La creazione di personaggi non giocanti (NPC) credibili nei videogiochi è stata tradizionalmente affrontata tramite macchine a stati ed alberi decisionali, strumenti che generano comportamenti ripetitivi, non si adattano a contesti nuovi e risultano privi di memoria e apprendimento. Questo lavoro di tesi presenta un'architettura per NPC in ambienti 3D che integra memoria persistente, recupero intelligente dei ricordi, pianificazione gerarchica e riflessione periodica sui propri comportamenti. Il sistema utilizza un modello linguistico (LLM) in esecuzione locale, privo di dipendenze da API cloud, e include un meccanismo di adattamento automatico a scene non preconfigurate. I risultati mostrano che l'NPC sviluppa comportamenti coerenti con i propri bisogni fisiologici dinamici, mostra capacità di apprendimento tramite le riflessioni e si adatta ad ambienti diversi senza richiedere configurazioni manuali. L'architettura proposta risulta così modulare, estensibile e completamente autonoma da servizi esterni.

Indice

Elenco delle Figure	iii
Elenco delle Tabelle	iv
1 Introduzione	1
1.1 Non-Playable Character: contesto e ruolo	1
1.2 Obiettivi	2
2 Dagli NPC tradizionali agli LLM: background e stato dell'arte	3
2.1 NPC tradizionali: analisi e limiti	3
2.1.1 Alberi decisionali	5
2.1.2 Macchine a stati finiti	6
2.1.3 Limiti degli approcci tradizionali	7
2.2 Gli LLM nei videogiochi: opportunità e sfide	7
2.2.1 LLM come strumenti per lo sviluppo di videogiochi	7
2.2.2 LLM per il controllo degli NPC	8
2.2.3 Sfide e limiti degli LLM	8
3 L'architettura di AmbraIA	10
3.1 Specifica PEAS	10
3.2 Caratteristiche dell'ambiente	11

3.3	Analisi del problema	12
3.4	Il lato Unity di AmbraIA	13
3.4.1	NPCController	14
3.4.2	InteractableObject	15
3.4.3	SceneAnalyzer	15
3.4.4	RuntimeCompiler	16
3.5	Il lato server di AmbraIA	16
3.5.1	Memory Stream	17
4	Conclusioni	20
	Bibliografia	21

Elenco delle figure

2.1	Struttura a moduli dell'IA nei videogiochi. Figura adattata da [1]. . .	4
2.2	Esempio di albero decisionale per un NPC.	5
2.3	Esempio di macchina a stati finiti per un NPC.	6
3.1	Panoramica del lato Unity di AmbraIA.	14
3.2	Panoramica del lato server di AmbraIA.	18

Elenco delle tabelle

CAPITOLO 1

Introduzione

1.1 Non-Playable Character: contesto e ruolo

I personaggi non giocanti (NPC) sono elementi fondamentali nel mondo videoludico. Sono parte integrante di un mondo interattivo e contribuiscono alla credibilità del mondo stesso. Ogni videogioco costruisce l'architettura dei propri NPC in base all'obiettivo del gioco: se parliamo di un gioco prettamente d'azione dove gli NPC rappresentano minacce per il giocatore, come per esempio nella maggior parte dei giochi della serie *Super Mario*, non è necessario che essi si comportino in maniera "umana", replicando tratti e azioni umane, ma devono semplicemente seguire il giocatore per attaccarlo. In altri videogiochi invece, come *The Sims*[2] o *Tomodachi Life*[3], dove si simula la quotidianità della vita di un essere umano, gli NPC sono il fulcro del design dei giochi: essi devono essere in grado di agire tra di loro e nell'ambiente circostante, reagire a stimoli fisiologici e così via. In pratica, si cerca di simulare il comportamento umano. La mente umana, d'altro canto, è molto complessa, e rappresentare i comportamenti che il pensiero genera è altrettanto complicato.

1.2 Obiettivi

AmbraIA si pone l'obiettivo di creare NPC capaci di agire in ambienti virtuali 3D differenti, principalmente su Unity. L'NPC reagisce agli elementi che compongono la scena, apprende le varie interazioni, soddisfa i propri bisogni fisiologici e agisce in base ai propri ricordi ed esperienze passate. In pratica, ciò che AmbraIA si propone è simulare comportamenti umani adattabili a qualsiasi ambiente 3D, seppur in forma molto semplificata rispetto alla realtà. Un esempio concreto: se l'NPC tende a mangiare solamente dolci, esaminando i propri ricordi riuscirà a capire che deve variare la propria dieta. Questo comportamento è reso possibile da continue chiamate a modelli linguistici locali, che supportano il sistema nel prendere decisioni, generare codice dinamico e riflettere sulle azioni passate, rendendo obsolete rigide strutture decisionali come le macchine a stati finiti. Inoltre, il progetto permette di adattare la propria scena al sistema decisionale in modo semi-automatico tramite interfacce dedicate. Questo non preclude la possibilità di modificare la scena in un secondo momento, cambiando animazioni, interazioni o gli stessi GameObject. AmbraIA punta quindi fortemente sull'adattabilità: l'obiettivo non è funzionare solo con determinati tipi di scene o videogiochi, ma simulare in modo semplificato il comportamento umano su scene diverse, che possono essere utilizzate per creare il proprio videogioco o, più in generale, un mondo virtuale più immersivo possibile.

Dagli NPC tradizionali agli LLM: background e stato dell'arte

2.1 NPC tradizionali: analisi e limiti

L'IA nei videogiochi è nata praticamente in simbiosi con i videogiochi stessi. Basti pensare a *Pong*[4], in cui l'avversario deve cercare di colpire la pallina evitando di subire punto. Un altro esempio importante è *Pac-Man*[5] del 1980, dove i quattro fantasmi hanno ciascuno un algoritmo differente per raggiungere il protagonista: Blinky, il fantasma rosso, imposta il suo obiettivo di movimento in base alla posizione attuale di Pac-Man, mentre Inky, il fantasma blu, si basa sulla posizione del fantasma rosso e di Pac-Man per accerchiarlo. Inizialmente gli NPC servivano principalmente per dare una sfida al giocatore. Oggi troviamo sistemi più complessi, alcuni dei quali simulano anche il comportamento umano, come *The Sims*[2], che simula la vita quotidiana delle persone. Come osserva Millington: "Now we have a massive diversity of AI in games. Many genres are still using the simple AI of 1979 because that's all they need" [1]. Nonostante l'IA nei videogiochi, e più in generale nel mondo dell'informatica, si sia evoluta molto, vari videogiochi moderni utilizzano ancora strutture vecchie di decenni. Il motivo risiede nella diversità dei generi videoludici

e nello scopo che ogni videogioco si prefigge, come già introdotto nel Capitolo 1. Normalmente un'IA per un NPC viene strutturata in tre moduli principali: movimento, decision making e strategia, come mostrato in Figura 2.1. Questa è una struttura proposta da Ian Millington per spiegare meglio il concetto di IA nei videogiochi [1]. I primi due moduli agiscono sul singolo agente, mentre la strategia agisce anche sulle azioni degli altri agenti.




Figura 2.1: Struttura a moduli dell'IA nei videogiochi. Figura adattata da [1].

Il Movimento è definito come il modulo che calcola un certo tipo di percorso e coordina il movimento dell'NPC. Il Decision Making permette all'NPC di decidere quali azioni compiere tra quelle disponibili. La Strategia serve a coordinare i due moduli sopracitati per farli lavorare insieme ad altri agenti. Non tutti i moduli sono necessari: *Super Mario Galaxy*[6] ha bisogno solo del modulo di movimento, dato che i nemici devono semplicemente inseguire il giocatore. Altri giochi d'azione più complicati come *Dark Souls*[7] richiedono decisioni più complesse — attaccare, parare, muoversi o curarsi — ma non tengono conto delle azioni degli altri nemici, rendendo superflua la Strategia. Tutto ciò rientra nelle scelte di design: ogni videogioco vuole trasmettere emozioni diverse e offrire un diverso grado di sfida. AmbraIA opera soprattutto sul campo del Decision Making, cercando di non coprire un genere preciso ma di creare un'IA che possa rendere gli NPC credibili in scene 3D differenti.

Il Decision Making viene affrontato principalmente tramite due strutture: gli alberi decisionali e le macchine a stati finiti.

2.1.1 Alberi decisionali

Non entrando troppo nei particolari, gli alberi decisionali sono strutture dati che vengono percorse ogni volta che deve essere presa una decisione. Sono formati da un insieme di nodi e da archi, cioè collegamenti direzionati tra due nodi che rappresentano le decisioni. Gli alberi sono caratterizzati dall'assenza di cicli. Le decisioni finali sono rappresentate dai nodi foglia, cioè nodi senza archi uscenti. Non appena c'è bisogno di prendere una decisione, l'albero viene percorso a partire dal suo nodo iniziale, detto radice. Viene percorso un arco piuttosto che un altro a seconda degli input che l'agente riceve, come la percezione del mondo esterno o il suo stato interno, ad esempio fame o stanchezza. Una volta arrivati al nodo foglia, la decisione è stata presa e si esegue l'azione designata, come mostrato in Figura 2.2.




Figura 2.2: Esempio di albero decisionale per un NPC.

2.1.2 Macchine a stati finiti

Le macchine a stati finiti sono formalmente definite come una quintupla composta da:

- Un insieme di stati Q
- Un alfabeto Σ
- Uno stato iniziale q_0
- Un insieme di stati finali Q_f
- Una funzione di transizione $\delta : Q \times \Sigma \rightarrow Q$

Nel contesto videoludico gli stati rappresentano una situazione in cui si trova l’NPC (in guardia, affamato, impaurito) che lo porta ad agire in un certo modo. Lo stato iniziale è la situazione di partenza dell’NPC. L’alfabeto rappresenta una serie di input. La funzione di transizione controlla se una condizione si verifica in un certo stato e, se ciò avviene, cambia lo stato dell’NPC. Gli stati finali rappresentano situazioni in cui l’NPC ha raggiunto un obiettivo o ha completato un comportamento. Le decisioni vengono quindi prese in base allo stato in cui si trova l’NPC in un determinato momento, come mostrato in Figura 2.3.




Figura 2.3: Esempio di macchina a stati finiti per un NPC.

2.1.3 Limiti degli approcci tradizionali

Questi approcci hanno molti vantaggi: sono strutturalmente semplici, possono essere trattati con valori primitivi e si possono combinare tra loro. Il limite più grande è la staticità di queste strutture: sono estremamente specifiche per il sistema in cui vengono implementate e non tengono conto delle azioni passate. Inoltre, ogni nuovo comportamento richiede la modifica manuale di stati, transizioni o rami dell'albero, rendendo difficile l'adattamento a contesti non previsti in fase di progettazione.

2.2 Gli LLM nei videogiochi: opportunità e sfide

L'intelligenza artificiale generativa e i Large Language Model rappresentano uno dei più grandi risultati dell'informatica moderna. Ormai gli LLM si sono introdotti nella maggior parte degli ambiti, lavorativi e non. Gli LLM sono modelli linguistici addestrati su enormi quantità di dati, che generano principalmente testo, ma si sta puntando sempre di più verso modelli General Purpose, in grado di generare anche immagini, audio, video e altro ancora.

2.2.1 LLM come strumenti per lo sviluppo di videogiochi

Anche nel mondo dei videogiochi gli LLM sono sbarcati, aiutando gli sviluppatori a creare strumenti che facilitano lo sviluppo. Un esempio è il progetto "LLMR: Real-time Prompting of Interactive Worlds using Large Language Models" di De La Torre et al. [8]. LLMR è un framework per la creazione di asset e scene 3D che utilizza un modello linguistico per la generazione di questi asset. Nell'architettura descritta nel paper è importante l'approccio human in the loop: l'utente inizia una conversazione con il modello per fornire tutte le informazioni necessarie alla generazione degli asset. A questo punto l'LLM genera i file C# che descrivono i vari elementi della scena. Una volta generati gli asset, l'utente può chiedere al modello modifiche automatiche oppure agire manualmente su di essi, prima di generare la scena completa.

2.2.2 LLM per il controllo degli NPC

Gli LLM inoltre assistono anche nella creazione di NPC. I comportamenti umani sono molto complessi, frutto di processi cognitivi articolati che comprendono l'analisi di ricordi ed esperienze passate, la percezione del mondo e lo stato fisiologico ed emotivo. I videogiochi che vogliono simulare i comportamenti umani, anche solo in parte, utilizzano per la maggior parte macchine a stati finiti enormi e molto specifiche per il gioco sviluppato; un esempio già citato è *Tomodachi Life* [3]. Gli LLM possono essere utilizzati per semplificare queste architetture.

Nel paper scientifico "LLM-Driven NPCs: Cross-Platform Dialogue System for Games and Social Platforms" di Song [9] viene proposto un prototipo di NPC che dialoga tramite LLM con il giocatore sia in-game tramite Unity, sia fuori dal gioco su Discord. Parlare nel gioco aumenta un parametro che indica il gradimento dell'NPC, cioè il grado di familiarità tra il giocatore e l'NPC. Più il gradimento è alto, più l'NPC sarà confidente verso il giocatore. In questo caso l'LLM ha il solo compito di generare output testuali in base agli input testuali del giocatore.

I Large Language Model però sono stati usati anche per elaborare decisioni più complesse, come in "Generative Agents: Interactive Simulacra of Human Behavior" di Park et al. [10], in cui viene progettata e implementata un'architettura che simula una cittadina di persone, le quali interagiscono tra loro, hanno la loro routine e la loro personalità. L'architettura cerca di simulare alcuni processi cognitivi della mente umana, come il deposito di ricordi in un database, l'estrazione di ricordi in base alla loro importanza e recenza, o la riflessione periodica sulle proprie azioni. Questo è un esempio di IA di strategia e decision making, poiché gli abitanti della cittadina interagiscono tra loro e prendono decisioni in base al mondo circostante e allo stato dell'NPC.

2.2.3 Sfide e limiti degli LLM

Nonostante le opportunità offerte, gli LLM presentano anche diverse criticità. Possono essere soggetti ad allucinazioni, generando informazioni non veritiere o incoerenti con il contesto; i tempi di esecuzione possono essere elevati, soprattutto quando il modello viene eseguito localmente; inoltre, in assenza di un'architettura

adeguata, tendono a ripetere le stesse risposte o gli stessi comportamenti. Queste sfide rendono necessario progettare sistemi che affianchino all'LLM componenti deterministiche in grado di gestire memoria, coerenza e affidabilità.

AmbraIA prende ispirazione dalle architetture sopracitate e cerca di creare un NPC che possa interagire in un ambiente 3D di Unity, prendendo decisioni coerenti con il suo stato fisiologico e la sua percezione dell'ambiente. AmbraIA non è una struttura pensata per un videogioco o un ambiente specifico, grazie a un sistema semi-automatico di matching tra GameObject e interazioni/animazioni definite dallo sviluppatore. L'LLM viene utilizzato da AmbraIA per pianificare le azioni, mappare le azioni in C# e generare riflessioni periodiche. Tutti questi aspetti vengono approfonditi nel Capitolo 3.

CAPITOLO 3

L'architettura di AmbraIA

AmbraIA è un'architettura cognitiva per agenti autonomi in ambienti 3D, supportata da modelli linguistici generativi. Questa architettura è divisa in vari moduli, ognuno con il compito di preparare i dati per il modulo successivo; il risultato finale viene inviato a Unity, dove prende la forma di uno script C# che permette all'agente di muoversi e interagire con la scena. Prima di descrivere in dettaglio ogni modulo, partiamo dalla definizione del problema dell'NPC che interagisce con l'ambiente e dalla descrizione dell'ambiente stesso.

3.1 Specifica PEAS

Per descrivere formalmente l'agente e il suo ambiente, si utilizza il modello PEAS (Performance, Environment, Actuators, Sensors), uno standard nella progettazione di agenti intelligenti.

Performance Le misure di prestazione adottate per valutare l'operato dell'agente sono:

- Coerenza delle azioni con lo stato fisiologico
- Varietà dei comportamenti nel tempo

- Tasso di successo della compilazione del codice C# generato
- Tempo di risposta del server, cioè la latenza tra richiesta e piano generato

Environment Gli elementi che formano l'ambiente sono:

- Una scena 3D Unity con oggetti interagibili (cibo, mobili, oggetti decorativi)
- Proprietà specifiche per ogni oggetto (nome, tag, azione disponibile, effetti fisiologici)
- Lo stato fisiologico dell'NPC (fame e stanchezza), che evolve dinamicamente nel tempo

Actuators Gli attuatori disponibili dall'agente sono:

- Movimento verso un oggetto (`MoveToTargetAndWait`)
- Interazione con un oggetto (`InteractWithAndWait`)
- Modifica dello stato fisiologico come conseguenza delle interazioni

Sensors I sensori attraverso i quali l'agente riceve input percettivi sono:

- Lista degli oggetti nel raggio di percezione (nome, distanza, azione, effetto)
- Stato fisiologico corrente (fame, stanchezza)
- Cronologia delle azioni più importanti e recenti
- Memoria a lungo termine

3.2 Caratteristiche dell'ambiente

L'ambiente in cui opera AmbraIA presenta le seguenti caratteristiche:

Singolo agente Il problema è modellato come un problema a singolo agente. Non sono presenti altri NPC o agenti concorrenti durante l'esecuzione, sebbene l'architettura sia predisposta per future estensioni multi-agente.

Parzialmente osservabile L'agente percepisce solo gli oggetti entro un raggio di percezione configurabile, non l'intera scena. Inoltre non ha accesso diretto allo stato interno degli oggetti (ad esempio, non sa se un cibo è già stato consumato).

Semi-deterministico Le interazioni con gli oggetti hanno effetti deterministici: mangiare una mela riduce sempre la fame di un valore fisso. Tuttavia, il processo decisionale basato su LLM introduce non-determinismo nella scelta delle azioni.

Sequenziale Il processo decisionale non è suddiviso in episodi indipendenti, ma consiste in una sequenza continua di pianificazione, esecuzione e aggiornamento della memoria. Le decisioni hanno conseguenze a lungo termine perché influenzano i ricordi che guideranno le scelte future.

Statico L'ambiente è statico durante l'esecuzione di un piano: gli oggetti non cambiano posizione o proprietà mentre l'NPC esegue le azioni. Lo stato fisiologico dell'NPC, invece, si modifica continuamente nel tempo.

Discreto Lo spazio degli stati è discreto. Le azioni disponibili sono in numero finito e lo stato fisiologico è rappresentato da valori normalizzati tra 0 e 1.

3.3 Analisi del problema

Il problema può essere formalizzato come un problema di pianificazione continua in un ambiente parzialmente osservabile, dove ogni stato è definito dalla combinazione di posizione dell'NPC, stato fisiologico, oggetti percepiti e contenuto del Memory Stream, cioè della memoria persistente.

Stati Configurazione corrente dell'NPC: posizione, fame, stanchezza e ricordi accumulati.

Stato iniziale NPC posizionato nella scena con fame e stanchezza iniziali e Memory Stream vuoto.

Azioni Movimento verso un oggetto oppure interazione con un oggetto.

Spazio degli stati Tutte le possibili combinazioni di posizioni, livelli fisiologici, oggetti percepiti e ricordi accumulati.

Test obiettivo Non esiste uno stato obiettivo finale. L’NPC deve mantenere un comportamento coerente e adattivo indefinitamente.

Il problema presenta le seguenti caratteristiche:

- Spazio degli stati potenzialmente illimitato, a causa della crescita continua del Memory Stream.
- Assenza di una soluzione ottima calcolabile: non esiste un comportamento “perfetto”.
- Necessità di bilanciare bisogni multipli simultaneamente (fame e stanchezza).
- Necessità di mantenere coerenza temporale, senza contraddire i ricordi e le riflessioni.

Per questi motivi, il problema non può essere risolto tramite alberi decisionali predefiniti o macchine a stati finite tradizionali, ma risulta adatto all’uso di LLM combinati con un’architettura di memoria, retrieval e riflessione.

3.4 Il lato Unity di AmbraIA

AmbraIA è suddivisa principalmente in due macro moduli: il lato Unity e il lato server. Il lato Unity ha il compito di raccogliere i dati di input dall’ambiente e di gestire i dati di output, cioè le azioni che l’NPC deve eseguire. È composto da quattro sotto-moduli principali, implementati come script C#:

- `NPCController`: permette all’NPC di muoversi e interagire con gli oggetti della scena.
- `SceneAnalyzer`: analizza la scena e invia i dati al server.
- `InteractableObject`: permette ai `GameObject` di diventare interagibili.
- `RuntimeCompiler`: compila a runtime il codice C# generato dal server e lo attacca all’NPC.

La Figura 3.1 mostra una panoramica del lato Unity.




Figura 3.1: Panoramica del lato Unity di AmbraIA.

3.4.1 NPCController

Questo componente permette di eseguire il piano di azioni compilato dal `RuntimeCompiler`. Fornisce i metodi per far muovere l'NPC e per interagire con gli oggetti interagibili, attivando animazioni ed effetti. Il movimento viene gestito tramite il `NavMesh`, una rappresentazione semplificata della geometria della scena che indica le aree calpestabili e gli ostacoli. In questo modo l'agente può calcolare percorsi validi evitando muri e oggetti non attraversabili. Una volta arrivato nei pressi dell'oggetto con cui interagire, l'NPC attiva l'animazione e l'effetto specifico dell'interazione, descritti dall'`InteractableObject`.

L'`NPCController` contiene inoltre i dati dello stato interno dell'NPC, che in questo caso sono fame e stanchezza: questi rappresentano i bisogni prioritari che l'NPC deve soddisfare. Entrambi sono rappresentati da valori decimali compresi

tra 0 e 1, dove 0 indica uno stato ottimale e 1 un bisogno critico. Fame e stanchezza aumentano gradualmente nel tempo: la fame cresce costantemente, mentre la stanchezza aumenta più rapidamente quando l’NPC si muove e più lentamente quando è fermo. Le interazioni con gli oggetti possono ridurre o aumentare questi valori.

3.4.2 InteractableObject

`InteractableObject` è il modulo che rappresenta l’interazione e viene associato ai `GameObject` che possono essere interagiti. Contiene quattro informazioni principali:

- il nome dell’interazione (ad esempio “Usa” o “Mangia”);
- l’animazione da attivare;
- la coordinata spaziale in cui l’NPC deve trovarsi per interagire con quell’oggetto;
- l’effetto, cioè il valore di modifica di fame e stanchezza dopo l’interazione.

Se a un `GameObject` non è associato un `InteractableObject`, questo non verrà considerato come oggetto interagibile. Il componente include inoltre un campo opzionale, `oggettoDaAttivare`, che permette di attivare un secondo `GameObject` al termine dell’interazione: questo consente di realizzare interazioni a più step, come nel caso del fornello che, una volta usato, fa apparire un piatto cotto.

3.4.3 SceneAnalyzer

`SceneAnalyzer` è il modulo che ha il compito di inviare i dati della scena al server tramite richiesta HTTP con endpoint `/npc/decide`. Il componente definisce il raggio di percezione dell’NPC: tutti gli oggetti interagibili che ricadono entro questo raggio vengono inseriti in una lista, dove ognuno è descritto da nome, tag, azione disponibile, effetto fisiologico e distanza dall’NPC. Nel calcolo dell’effetto, `SceneAnalyzer` legge direttamente i valori di `fameEffect` ed `energyEffect` dall’`InteractableObject` e li classifica come *hunger*, *energy*, *both* o *none*.

Oltre agli oggetti vicini, l'analyser invia al server anche lo stato fisiologico corrente dell'NPC, le ultime azioni eseguite e le riflessioni accumulate. Se l'NPC ha una fame o una stanchezza maggiore o uguale a 0.7, l'Analyzer notificherà la criticità. In questo modo il server ha tutte le informazioni necessarie per pianificare le azioni successive. Se il file C# generato dal server contiene un errore di compilazione, lo `SceneAnalyzer` notifica l'errore al server e richiede un nuovo tentativo: questo meccanismo di retry può avvenire fino a un massimo di tre volte, sia per errori di compilazione sia per errori HTTP.

Quando un'azione viene completata, lo `SceneAnalyzer` invia una notifica al server tramite l'endpoint `/npc/action-done`, in modo che l'azione venga registrata nella memoria a lungo termine. Questa comunicazione avviene separatamente dalla richiesta di pianificazione, così il Memory Stream rimane sempre aggiornato.

3.4.4 RuntimeCompiler

`RuntimeCompiler` ha il compito di compilare il piano d'azione, scritto in codice sorgente C# e generato dal server, per poi attaccarlo all'NPC. Unity normalmente compila tutto il codice a tempo di build, ma in questo caso il codice non esiste finché il server non lo genera, quindi è necessario compilarlo durante l'esecuzione del gioco. Per farlo, il componente utilizza Roslyn, il compilatore C# ufficiale di Microsoft.

Il processo avviene interamente in memoria: se la compilazione ha successo, la classe generata viene attaccata al `GameObject` dell'NPC, sostituendo quella del piano precedente. Se invece la compilazione fallisce, `RuntimeCompiler` restituisce una stringa con gli errori riscontrati, che `SceneAnalyzer` invierà al server per richiedere una correzione.

3.5 Il lato server di AmbraIA

Il lato server ha il compito di elaborare i dati ricevuti da Unity e di generare un piano d'azione sotto forma di file C#, che viene poi rimandato indietro. È stato implementato interamente in Python. Per orchestrare i diversi sotto-moduli del server ho scelto di utilizzare LangGraph, un framework open source sviluppato da

LangChain. LangGraph permette di costruire workflow complessi con agenti di AI generativa, gestendo in modo chiaro il flusso di dati tra un modulo e l'altro. Il server è composto da sei moduli principali:

- `Memory Stream`: memoria persistente che registra tutte le esperienze dell'NPC.
- `Retrieval`: recupera dal Memory Stream i ricordi più rilevanti per la situazione attuale.
- `Planner`: genera un piano d'azione gerarchico basato sulla scena, sui ricordi e sulle riflessioni, tramite una chiamata a un LLM.
- `Builder`: traduce il piano in codice C# eseguibile da Unity, sempre tramite LLM.
- `Inspector`: valida il codice generato, verificando che non contenga errori o placeholder.
- `Reflector`: analizza periodicamente le esperienze recenti e produce riflessioni di alto livello, tramite una chiamata all'LLM.

La Figura 3.2 mostra una panoramica del lato server.




Figura 3.2: Panoramica del lato server di AmbraIA.

3.5.1 Memory Stream

Il Memory Stream rappresenta la memoria permanente dell'architettura. Consiste in un file JSON in cui sono raccolti tutti i "ricordi" dell'NPC, cioè le sue azioni passate. Questo serve a simulare i ricordi umani e aiuta a evitare comportamenti ripetitivi,

incoerenti, o che in passato hanno portato a effetti negativi. Ogni ricordo è composto da:

- `id`: identificativo alfanumerico del ricordo;
- `content`: descrizione testuale del ricordo;
- `timestamp`: momento in cui è avvenuto il ricordo;
- `importance`: numero intero da 1 a 10 che indica l'importanza del ricordo. Non tutte le esperienze hanno lo stesso valore: mangiare una mela quando si ha fame è più significativo che mangiarla quando si è già sazi. Per questo il punteggio viene assegnato dall'LLM al momento della creazione del ricordo, valutando l'impatto sullo stato fisico, la novità dell'evento e l'utilità per le decisioni future. Questo valore influenza il Retrieval, dando più peso ai ricordi ritenuti più importanti;
- `type`: tipo del ricordo, che può essere `action`, `observation` o `reflection`;
- `embedding`: vettore di 768 numeri che rappresenta il significato del testo. Viene generato tramite `nomic-embed-text`, un modello eseguito localmente che trasforma una frase in una rappresentazione numerica. Due frasi con significato simile avranno vettori vicini nello spazio, anche se non condividono le stesse parole: ad esempio "Ho mangiato una mela" e "Ho consumato del cibo" producono embedding molto simili. Questo permette al Retrieval di confrontare i ricordi con la situazione attuale in modo semantico, senza dover cercare parole chiave.

La Lista 3.1 mostra un esempio di ricordo salvato nel Memory Stream.

Listing 3.1: Esempio di ricordo nel Memory Stream.

```
1      {
2          "id": "mem_a3f2c1d4",
3          "content": "Mangia su Mela",
4          "timestamp": 1726000000.0,
5          "importance": 6,
```

```
6         "type": "action",
7         "embedding": [0.12, -0.34, 0.78, "...altri 765
                        valori..."]
8     }
```

CAPITOLO 4

Conclusioni

Le conclusioni qui...

Bibliografia

- [1] I. Millington and J. Funge, *Artificial Intelligence for Games*, 3rd ed. Boca Raton, FL: CRC Press, 2019. (Citato alle pagine iii, 3 e 4)
- [2] Maxis, "The sims," 2000, videogioco. (Citato alle pagine 1 e 3)
- [3] Nintendo, "Tomodachi life," 2013, videogioco. (Citato alle pagine 1 e 8)
- [4] Atari, "Pong," 1972, videogioco. (Citato a pagina 3)
- [5] Namco, "Pac-man," 1980, videogioco. (Citato a pagina 3)
- [6] Nintendo, "Super mario galaxy," 2007, videogioco. (Citato a pagina 4)
- [7] FromSoftware, "Dark souls," 2011, videogioco. (Citato a pagina 4)
- [8] F. De La Torre, C. M. Fang, H. Huang, A. Banburski-Fahey, J. Amores Fernandez, and J. Lanier, "Llmr: Real-time prompting of interactive worlds using large language models," in *Proceedings of the CHI Conference on Human Factors in Computing Systems*, Honolulu, HI, USA, 2024. (Citato a pagina 7)
- [9] L. Song, "Llm-driven npcs: Cross-platform dialogue system for games and social platforms," *arXiv preprint arXiv:2504.13928*, 2025. (Citato a pagina 8)
- [10] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of*

the 36th Annual ACM Symposium on User Interface Software and Technology (UIST), 2023. (Citato a pagina 8)

Ringraziamenti

Ringraziamenti qui...